Classificação de câncer de mama (maligno x benigno) com Machine Learning

Tech Challenge – Fase 1

Relatório técnico

Autores

Matheus Silva Vilas Boas

Tatiane Pereira Rocha

Cyro Pereira Silva Souza

Repositório: https://github.com/matheussvb/posGraduacaoTrabalhoV6

Vídeo de demonstração: https://youtu.be/zjzghIY_BbQ

Dataset: https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data

Novembro de 2026

1. Problema

Um hospital universitário quer um sistema de apoio ao diagnóstico para a análise inicial de exames. Escolhemos um problema de classificação com dados em tabela. A partir das medidas de um exame de punção aspirativa por agulha fina (PAAF) de um nódulo de mama, o modelo prevê se o tumor é maligno ou benigno.

2. Dataset

Usamos o Breast Cancer Wisconsin (Diagnostic), disponível no Kaggle (origem: repositório UCI). São 569 exames e 30 variáveis numéricas medidas na imagem dos núcleos das células. Para cada uma das 10 características (raio, textura, perímetro, área, suavidade, compacidade, concavidade, pontos côncavos, simetria e dimensão fractal) há três medidas: a média (_mean), o erro padrão (_se) e o pior valor (_worst). A coluna alvo é diagnosis, com M para maligno e B para benigno.

Item	Valor
Exames	569
Variáveis de entrada	30
Benignos	357 (62,7%)
Malignos	212 (37,3%)
Valores ausentes	0
Linhas duplicadas	0

3. Exploração dos dados

A base tem mais exames benignos do que malignos (Figura 1). O desbalanceamento não é extremo, mas pesa na escolha da métrica e justifica a divisão estratificada e o peso de classe balanceado.

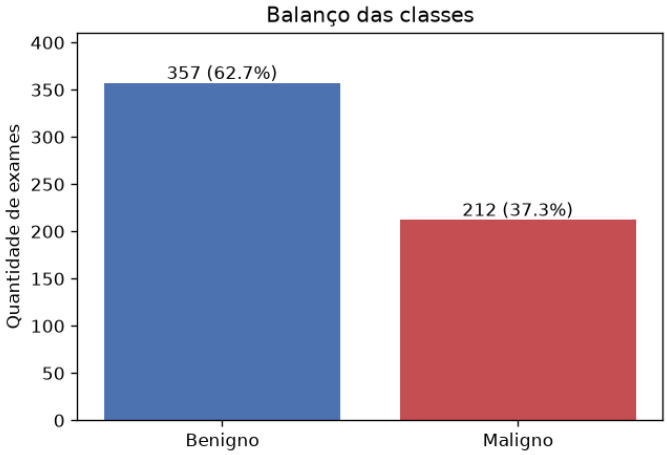


Figura 1 – Quantidade de exames por diagnóstico.

Estatísticas descritivas das principais variáveis

Variável	Média	Desvio	Mínimo	Máximo
radius_mean	14,127	3,524	6,981	28,110
texture_mean	19,290	4,301	9,710	39,280
perimeter_mean	91,969	24,299	43,790	188,500
area_mean	654,889	351,914	143,500	2501,000
concavity_mean	0,089	0,080	0,000	0,427
concave_points_mean	0,049	0,039	0,000	0,201

As escalas são muito diferentes: a área média chega a 2501 e a concavidade não passa de 0,427. KNN e regressão logística são sensíveis a isso, então o escalonamento entra no pipeline.

Média por diagnóstico

Variável	Benigno	Maligno	Maligno / Benigno
radius_mean	12,147	17,463	1,44
texture_mean	17,915	21,605	1,21
perimeter_mean	78,075	115,365	1,48
area_mean	462,790	978,376	2,11
concavity_mean	0,046	0,161	3,49
concave_points_mean	0,026	0,088	3,42

Os tumores malignos têm núcleos maiores (raio, perímetro e área) e mais irregulares: concavidade e pontos côncavos são mais de três vezes maiores. Nas Figuras 2 e 3 essas variáveis separam bem as classes; a textura se sobrepõe bastante e sozinha diz pouco.

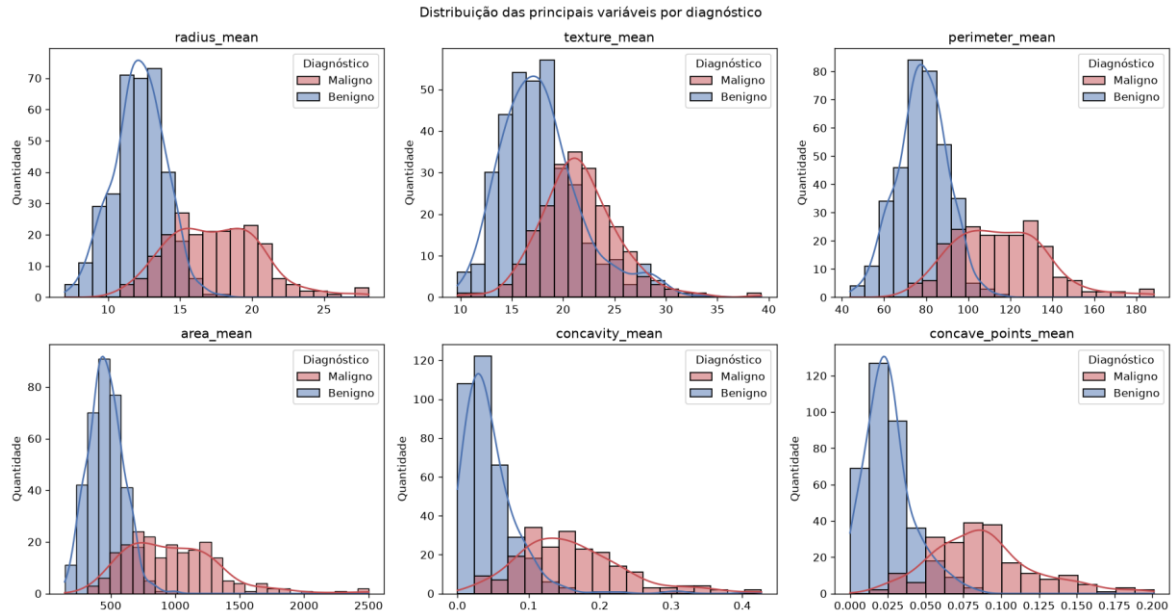


Figura 2 – Distribuição das principais variáveis por diagnóstico.

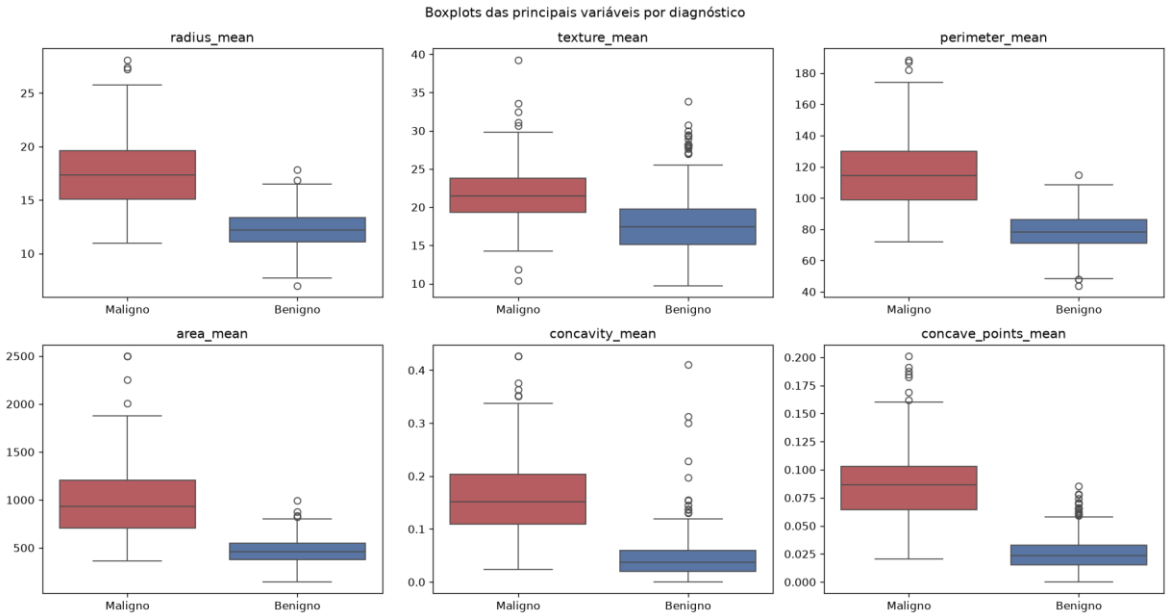


Figura 3 – Boxplots das principais variáveis por diagnóstico.

Análise de correlação

O mapa de calor (Figura 4) mostra correlação muito alta entre raio, perímetro e área (todas medem o tamanho do núcleo) e entre as medidas _mean e _worst de cada característica. As variáveis mais correlacionadas com o diagnóstico maligno são concave_points_worst (0,79), perimeter_worst (0,78), concave_points_mean (0,78), radius_worst (0,78) e perimeter_mean (0,74) (Figura 5). Mesmo assim mantivemos as 30 variáveis: a regularização da regressão logística e a Random Forest lidam bem com redundância.

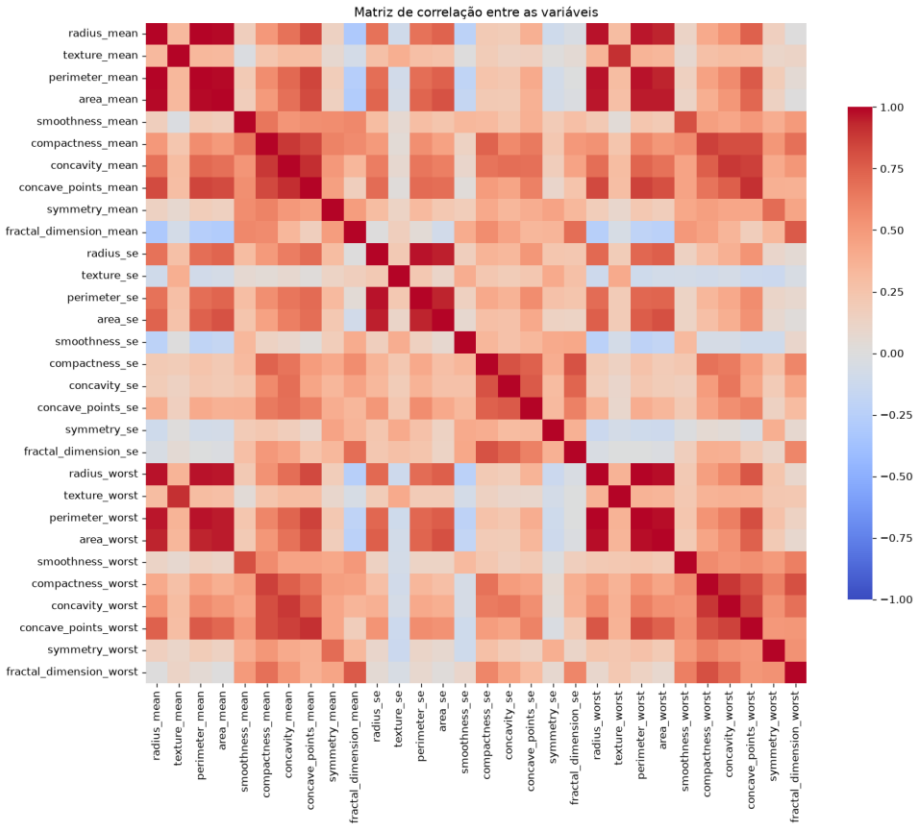


Figura 4 – Matriz de correlação entre as 30 variáveis.

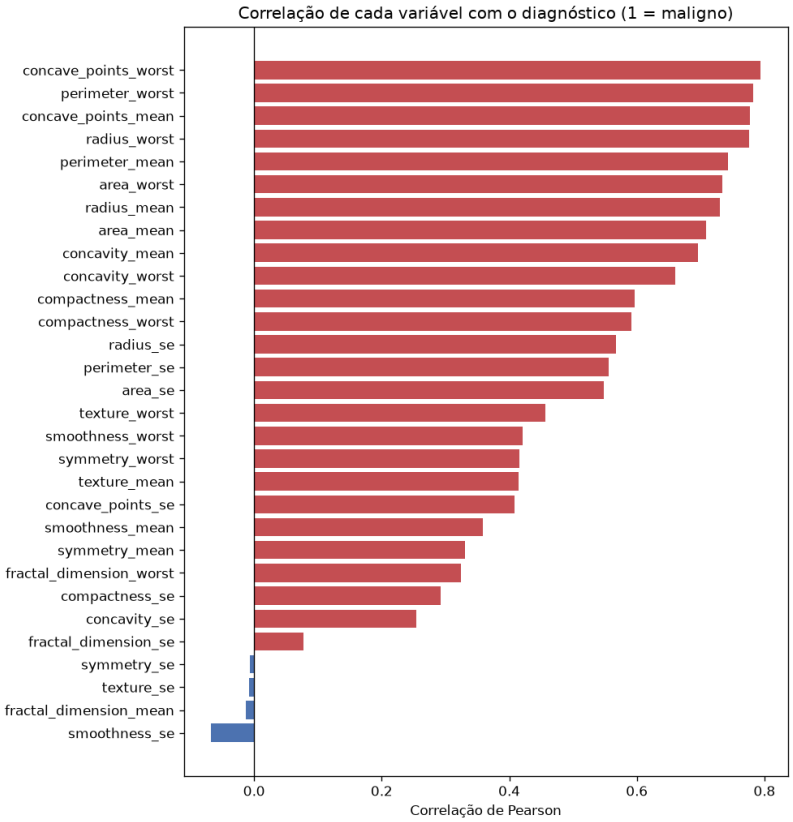


Figura 5 – Correlação de cada variável com o diagnóstico.

4. Pré-processamento

- **Colunas sem informação:** removemos o identificador (id) e a coluna vazia do arquivo do Kaggle (Unnamed: 32); nomes com espaço viraram underline.
- **Inconsistências:** removemos linhas duplicadas, padronizamos o diagnóstico (maiúsculas e sem espaços) e descartamos linhas com diagnóstico diferente de M ou B. Valores não numéricos ou negativos viram ausentes.
- **Valores ausentes:** a base não tem nenhum, mas o pipeline tem um imputador pela mediana para exames novos que cheguem incompletos.
- **Variáveis categóricas:** só o diagnóstico, convertido para 1 (maligno) e 0 (benigno); as demais já são numéricas.
- **Escalonamento:** StandardScaler (média 0 e desvio 1) dentro de um Pipeline do scikit-learn junto com o modelo. Imputador e escalonador aprendem só com o treino e são aplicados à validação e ao teste, sem vazamento.

Separação entre treino, validação e teste

Dividimos os dados de forma estratificada e com semente fixa 42: 70% treino (397 exames), 15% validação (86) e 15% teste (86). O treino ajusta os modelos, a validação escolhe o melhor e o teste é usado uma única vez, no final, só com o modelo escolhido.

5. Modelos usados e por quê

- **Regressão Logística:** modelo linear, rápido e interpretável, que devolve a probabilidade de malignidade. A regularização padrão (L2) ajuda com variáveis correlacionadas, e class_weight='balanced' dá mais peso à classe maligna.

- **KNN (k = 7):** classifica um exame pelos 7 exames mais parecidos do treino. Não assume fronteira linear; depende do escalonamento, que o pipeline garante.
- **Random Forest (300 árvores):** conjunto de árvores de decisão que captura relações não lineares e tolera variáveis redundantes e valores extremos. Também usa class_weight='balanced'.

6. Métrica principal

Os dois erros não custam o mesmo. Um falso positivo (benigno previsto como maligno) leva a exames complementares; um falso negativo (maligno previsto como benigno) pode atrasar o tratamento de um câncer. Por isso a métrica principal é o recall da classe maligna: de todos os tumores malignos, quantos o modelo encontrou. Como chamar tudo de maligno daria recall de 100%, acompanhamos também precision, F1 e accuracy.

Critério de escolha do modelo: maior recall na validação; em caso de empate, o recall médio da validação cruzada de 5 partes no treino e, depois, o F1.

7. Resultados

Modelo	Accuracy	Precision	Recall	F1	Recall CV (treino)
Regressão Logística	0,965	0,939	0,969	0,954	0,953
KNN	0,977	0,969	0,969	0,969	0,885
Random Forest	0,965	0,968	0,938	0,952	0,939

A coluna Recall CV é a média do recall em validação cruzada de 5 partes feita só no treino. Ela confere se o resultado não foi sorte de uma única divisão. Os três modelos ficaram próximos: Regressão Logística e KNN empataram no recall (0,969) e o desempate pelo Recall CV (0,953 contra 0,885) escolheu a Regressão Logística.

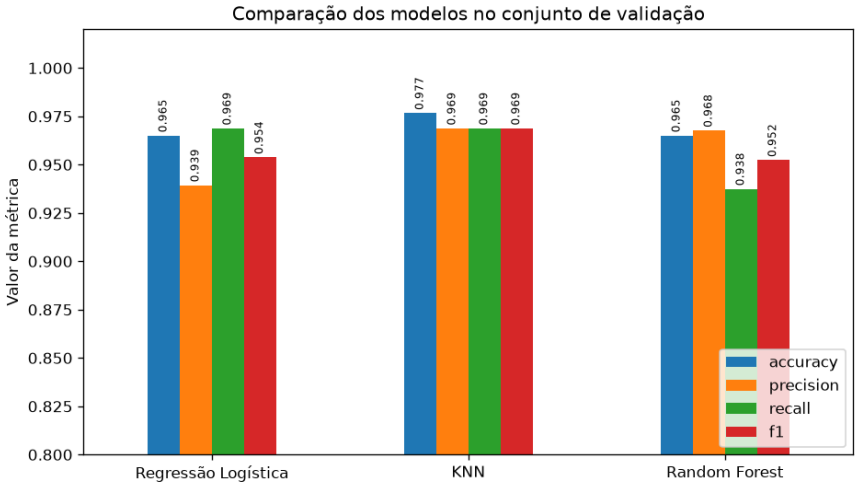


Figura 6 – Métricas dos modelos na validação.



Figura 7 – Matrizes de confusão na validação.

Avaliação final no teste (Regressão Logística)

Accuracy	Precision	Recall	F1
0,988	1,000	0,969	0,984

No teste, que o modelo nunca tinha visto, a Regressão Logística encontrou 31 dos 32 tumores malignos (recall de 96,9%). Houve 1 falso negativo e nenhum falso positivo (Figura 8). O recall igual ao da validação é um bom sinal, mas o teste tem só 86 exames (32 malignos): cada erro muda o recall em cerca de 3 pontos. Para confirmar que o modelo generaliza, é preciso testar em outra base.

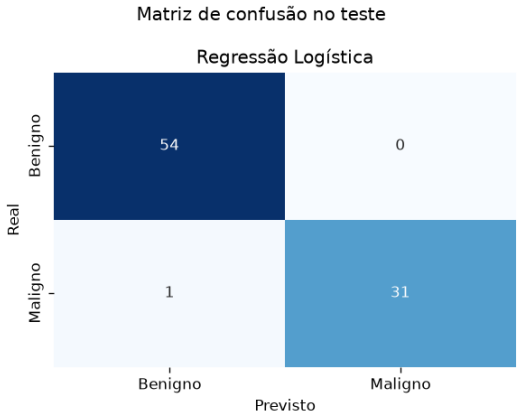


Figura 8 – Matriz de confusão do modelo final no teste.

8. Interpretação do modelo

Usamos duas técnicas que funcionam com qualquer modelo. A importância por permutação embaralha uma variável por vez no conjunto de teste e mede quanto o F1 cai. O SHAP calcula, para cada exame do teste, quanto cada variável empurrou a probabilidade de malignidade para cima ou para baixo.

Variáveis mais importantes por permutação (Figura 9): texture_worst, radius_se, concave_points_mean, radius_worst e concave_points_worst. Variáveis com maior impacto médio no SHAP (Figuras 10 e 11): texture_worst, radius_se, radius_worst, concave_points_mean e concave_points_worst.

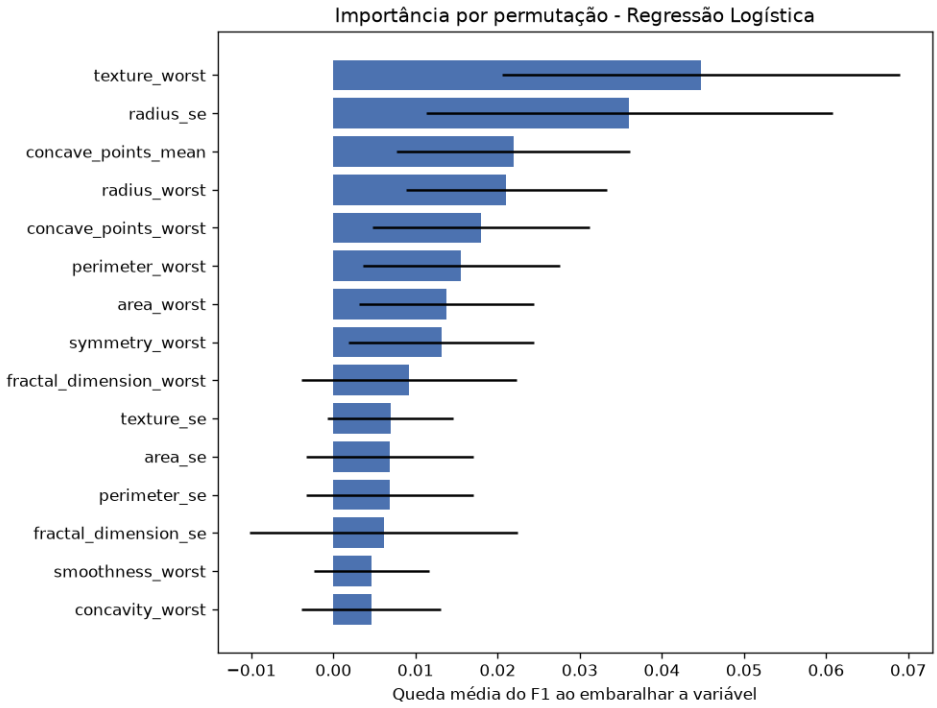


Figura 9 – Importância por permutação no teste.

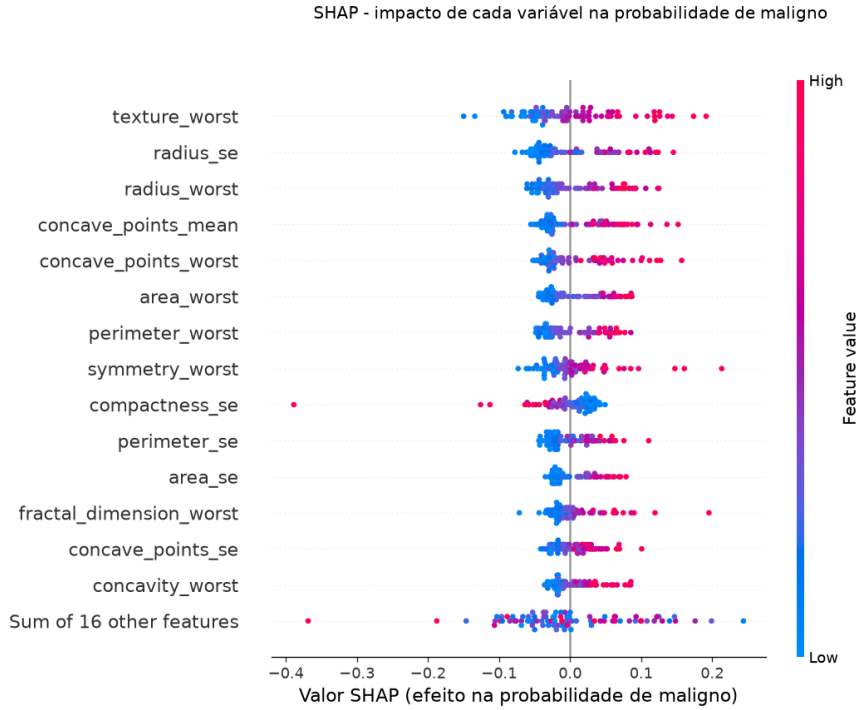


Figura 10 – SHAP: cada ponto é um exame; vermelho é valor alto da variável.

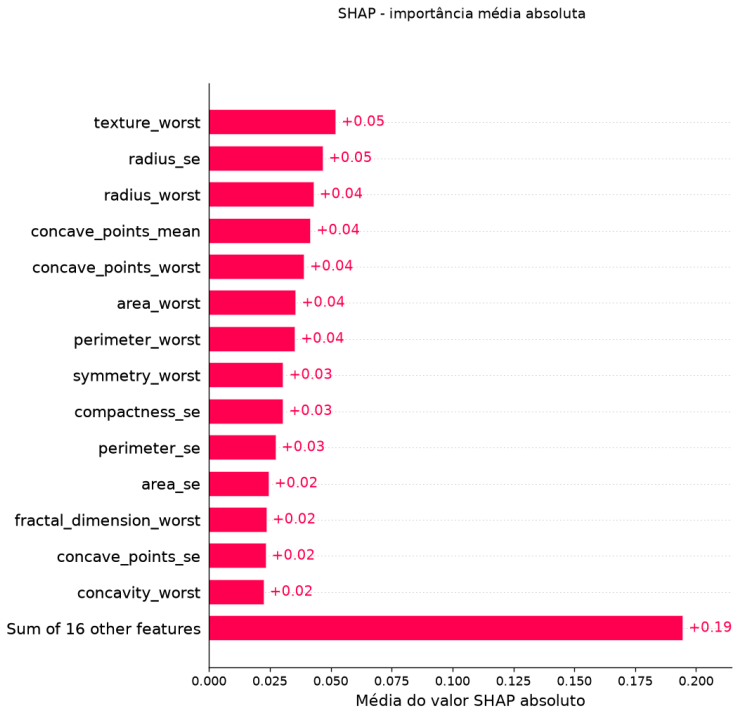


Figura 11 – SHAP: impacto médio absoluto de cada variável.

As duas técnicas apontam para as famílias que a exploração já destacava: tamanho do núcleo e irregularidade do contorno, principalmente nas medidas _worst. Elas acrescentam a textura, que sozinha separa pouco mas ganha peso combinada com as outras. No SHAP, valores altos dessas variáveis aumentam a probabilidade de malignidade, o que combina com o conhecimento médico: células malignas têm núcleos maiores e mais deformados.

A Figura 12 mostra a explicação de um exame maligno do teste: todas as variáveis principais empurram a probabilidade para cima. É o tipo de informação que pode acompanhar a previsão.

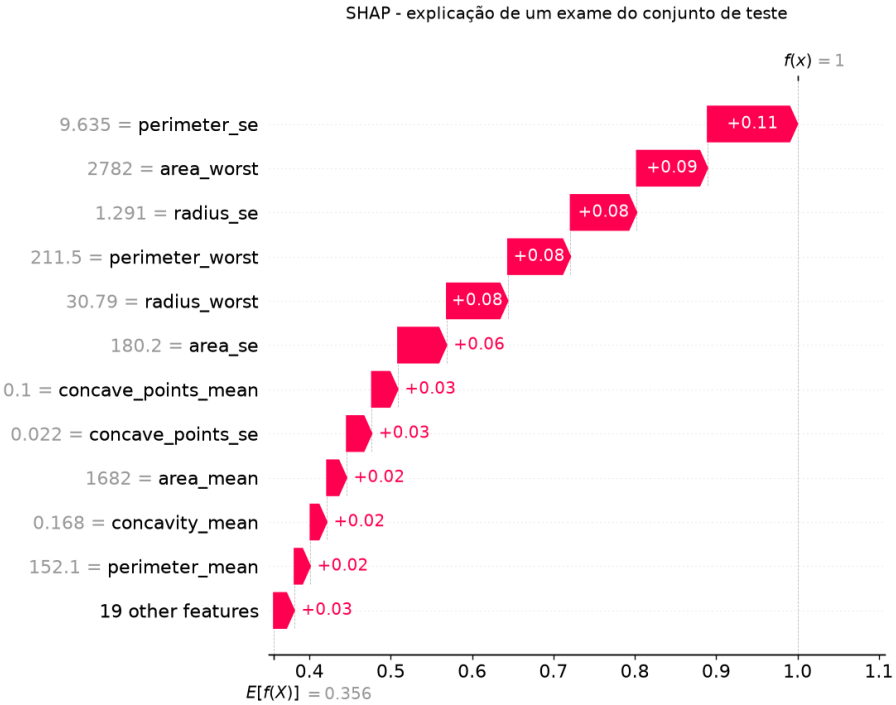


Figura 12 – SHAP de um exame maligno do conjunto de teste.

9. Discussão crítica

O modelo pode ser usado na prática?

Pode, como apoio à triagem, depois de ser validado com dados do próprio hospital e de passar pelos requisitos regulatórios. O sistema recebe as medidas do exame e devolve a probabilidade de malignidade com a explicação SHAP. Os casos de maior risco sobem na fila de revisão do patologista ou do mastologista.

Limitações

- A base é pequena (569 exames), vem de um único centro e as 30 medidas dependem de um processo específico de extração de imagem. Antes de qualquer uso real, o modelo precisa ser validado com dados do próprio hospital.
- O teste é pequeno (86 exames, 32 malignos); as métricas têm margem de variação e devem ser lidas com cautela.
- Um sistema em produção precisaria de monitoramento, registro das previsões, cuidado com dados pessoais (LGPD) e aprovação regulatória como dispositivo médico.

10. Conclusão

Construímos um pipeline completo em Python: carga, limpeza, exploração, pré-processamento, treino de três modelos, escolha pela validação e avaliação única no teste. A Regressão Logística alcançou recall de 96,9% e F1 de 0,984 no teste, e as explicações mostram que ela decide com base em características que fazem sentido clinicamente. Na prática o modelo entra como apoio: o médico vê a previsão e as variáveis que mais pesaram e tem a palavra final. É uma boa base para a próxima fase do sistema.

11. Links e referências

- Repositório: https://github.com/matheussvb/posGraduacaoTrabalhoV6
- Vídeo: https://youtu.be/zjzghIY_BbQ
- Dataset: https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data

Referências

WOLBERG, W.; MANGASARIAN, O.; STREET, N.; STREET, W. **Breast Cancer Wisconsin (Diagnostic)**. UCI Machine Learning Repository, 1993. DOI: https://doi.org/10.24432/C5DW2B. Acesso em: 3 nov. 2026.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, v. 12, n. 85, p. 2825-2830, 2011. Disponível em: https://jmlr.org/papers/v12/pedregosa11a.html. Acesso em: 3 nov. 2026.

LUNDBERG, S. M.; LEE, S.-I. A Unified Approach to Interpreting Model Predictions. In: GUYON, I. et al. (ed.). **Advances in Neural Information Processing Systems 30**. Curran Associates, 2017. Disponível em: https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html. Acesso em: 3 nov. 2026.